

Logistic Regression

用于分类，主要是得到预测结果的概率值：

$$f(x) = P(y|x) \in [0, 1]$$

给定数据集 $D = \left\{ (\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_n, y_n) \right\}, y_i \in \{-1, +1\}$

预测函数：

$$s(z) = \frac{1}{1 + \exp(-z)}$$

$$z = \sum w_i x_i = \vec{w}^T \vec{x}$$

$$h(x) = \frac{1}{1 + \exp(-\vec{w}^T \vec{x})}$$

Error function 通过极大似然估计得到：

目标函数 $f(x)$ 下，产生 D 的概率：

$$P_f(D) = P(\vec{x}_1) f(\vec{x}_1) P(\vec{x}_2) f(\vec{x}_2) \dots P(\vec{x}_n) f(\vec{x}_n)$$

预测函数 $h(x)$ 下，产生 D 的概率：

$$P_h(D) = P(\vec{x}_1) h(\vec{x}_1) P(\vec{x}_2) h(\vec{x}_2) \dots P(\vec{x}_n) h(\vec{x}_n)$$

若 h 与 f 很接近，则 $P_h(D)$ 与 $P_f(D)$ 很接近，称 $P_h(D)$ 为似然。

f 既然产生了 D ，可以想成“ f 产生 D 的概率极大”（所以 f 产生了 D ）；

因此，最佳的 h ，与 f 最接近的 h ，其产生 D 的概率也该是极大的。

所以，要求最大似然 $\max_h \text{likelihood}(h)$ ，从而得到最佳的预测函数 $\arg \max_h P_h(D)$ 。

$$P_h(D) = P(\vec{x}_1) P(y_1 | \vec{x}_1) P(\vec{x}_2) P(y_2 | \vec{x}_2) \dots P(\vec{x}_n) P(y_n | \vec{x}_n)$$

$$\because P(y_i | \vec{x}_i) = \begin{cases} h(\vec{x}_i), & \text{for } y_i = +1 \\ 1 - h(\vec{x}_i), & \text{for } y_i = -1 \end{cases}$$

又 \because logistic 函数有性质： $1 - h(x) = h(-x)$

$$\therefore P(y_i | \vec{x}_i) = \begin{cases} h(x), & \text{for } y_i = +1 \\ h(-x), & \text{for } y_i = -1 \end{cases} = h(y_i x_i)$$

$$\therefore P_h(D) = P(\vec{x}_1)h(y_1 \vec{x}_1) P(\vec{x}_2)h(y_2 \vec{x}_2) \dots P(\vec{x}_n)h(y_n \vec{x}_n)$$

$$\therefore P(\vec{x}_i) \text{ 固定, 所以上式 } \propto \prod h(y_i \vec{x}_i)$$

$$\therefore \max_h P_h(D) \propto \prod h(y_i \vec{x}_i)$$

$$\therefore \text{每个 } h \text{ 对应一个参数 } \vec{w}, \therefore \max_{\vec{w}} \text{likelihood}(\vec{w}) \propto \prod s(y_i \vec{w}^T \vec{x}_i)$$

$$\therefore \text{连乘不容易求解, 所以取对数变成连加: } \max_{\vec{w}} \ln \prod s(y_i \vec{w}^T \vec{x}_i) = \max_h \sum \ln s(y_i \vec{w}^T \vec{x}_i)$$

\therefore 似然最大, 即误差最小, 目的也是求误差函数, 所以 \max 变为 \min 加一个负号:

$$\min_{\vec{w}} \frac{1}{N} \sum -\ln s(y_i \vec{w}^T \vec{x}_i)$$

$$\therefore s(z) = \frac{1}{1 + \exp(-z)} \text{ 代入上式得到: } \min_{\vec{w}} \frac{1}{N} \sum \ln(1 + \exp(-y_i \vec{w}^T \vec{x}_i))$$

其中, 定义交叉熵错误 *cross entropy error*: $\text{err}(\vec{w}, \vec{x}_i, y_i) = \ln(1 + \exp(-y_i \vec{w}^T \vec{x}_i))$

$$\text{综上, error function: } \frac{1}{N} \sum \ln(1 + \exp(-y_i \vec{w}^T \vec{x}_i)) = \frac{1}{N} \sum \text{err}(\vec{w}, \vec{x}_i, y_i)$$

如何解 \min error function 得到最佳 \vec{w} : 梯度及梯度下降

$$E(\vec{w}) = \frac{1}{N} \sum \ln(1 + \exp(-y_i \vec{w}^T \vec{x}_i))$$

$$\begin{aligned} \nabla E(\vec{w}) &= \frac{\partial E(\vec{w})}{\partial w_i} = \frac{1}{N} \sum \left(\frac{1}{\square} \right) (\exp(\Delta)) (-y_i \vec{x}_i) \\ &= \frac{1}{N} \sum \left(\frac{\exp(\Delta)}{1 + \exp(\Delta)} \right) (-y_i \vec{x}_i) \\ &= \frac{1}{N} \sum s(\Delta) (-y_i \vec{x}_i) \\ &= \frac{1}{N} \sum s(-y_i \vec{w}^T \vec{x}_i) (-y_i \vec{x}_i) \end{aligned}$$

因为 $E(\vec{w})$ 是连续, 可微的凸函数, 所以令 $\nabla E(\vec{w}) = 0$, 可解的最佳 \vec{w} 。

另外有迭代优化方法来得到最佳 \vec{w} :

1. 设置权值向量 \vec{w} 初始值为 \vec{w}_0 , 设迭代次数为 t , $t = 0, 1, 2, \dots$;

2. 计算梯度 $\nabla E(\vec{w}_t) = \frac{1}{N} \sum s(-y_i \vec{w}_t^T x_i) (-y_i x_i)$;

3. 更新 \vec{w} : $\vec{w}_{t+1} = \vec{w}_t - \eta \nabla E(\vec{w}_t)$

4. 直到 $\nabla E(\vec{w}_t) \approx 0$ 或迭代次数足够多